

AI 信息周报

Artificial Intelligence Weekly Report

2026/06/15 · 周一发布

#超级App入口

#调用量反超

#世界模型

#具身智能

#AI政策

本周速览 · 国内

WEEKLY OVERVIEW · 8 条

01

微信发布 AI 生态开发者指引，AI Agent 正式面向小程序开发者开放

6 月 9 日
`超级入口` `应用Agent`

02

中国大模型周调用量连续 6 周超越美国，全球 Top5 占 4 席

6 月 9 日
`调用量` `国产模型`

03

工信部印发"AI+信息通信"实施意见，明确 1ms 算力圈与 AI 终端路线图

6 月 10 日
`算力网络` `政策`

04

国家网信办、市场监管总局联合印发《网络测评活动规范》

6 月 9 日
`AI评测` `内容治理`

05

智源大会发布"悟界"世界模型系列，Kimi K2.7 Code 编程模型开源

6 月 12 日
`世界模型` `编程模型`

06

外媒报道蚂蚁集团内测 AI 版支付宝，超级 App AI 入口竞争升级

6 月 14 日
`超级App` `AI入口`

07

美国扩大涉军企业名单，阿里、百度、宇树等中国科技企业被列入

6 月 9 日
`地缘科技` `供应链`

08

AI 陪伴监管进入生效前一个月倒计时

6 月 15 日
`AI陪伴` `数据治理`

本周速览 · 全球

WEEKLY OVERVIEW · 8 条

01

Anthropic 发布 Claude Fable 5 与 Mythos 5...

6 月 9 日、12 日
`模型治理` `出口管制`

02

Google DeepMind 发布 DiffusionGemma，尝试用扩...

6 月 10 日
`开源模型` `本地AI`

03

OpenAI 宣布收购 Ona，为 Codex 引入持久化、安全云端执行环境

6 月 11 日
`长时Agent` `云沙箱`

04

NVIDIA 披露首轮 AgentPerf 结果，Agent 工作负载开始拥...

6 月 12 日
`Agent基准` `算力效率`

05

OpenAI 推出全球合作伙伴网络，计划投入 1.5 亿美元并认证 30 万...

6 月 14 日
`企业落地` `渠道生态`

06

OpenAI 与 Oracle 打通既有云采购额度，降低企业采用 Codex...

6 月 10 日
`企业AI` `云生态`

07

Anthropic 与 TCS 合作进入金融、医疗、公共部门等强监管行业

6 月 12 日
`行业Agent` `合规`

08

新研究将 Agent 记忆定义为隐私、效用与可删除性的共同优化问题

6 月 9 日 (北京时间)
`长期记忆` `隐私` `遗忘`

01

一、国内 AI 热点

微信开放 Agent 接入，支付宝被曝内测 AI 版本

微信把小程序生态变成 AI 的"手脚"，支付宝从支付工具重构为 AI 原生入口——两大超级 App 的 AI 竞争从"能力建设"进入"产品形态对抗"。

微信策略

Agent → 小程序

数百万小程序成为可调工具

支付宝策略

AI 原生重构

AI 助手"阿宝"替代功能列表

核心变量

谁能调度最多服务

身份+支付+小程序/服务闭环

解读

- 微信：自动模式读取源码自动解析；开发模式自定义调用逻辑，通过平台审核后接入
- 支付宝：此前已推出"AI付"和"AI收"，为智能体提供完整支付闭环
- 真正关键的是 Agent 调用协议是否统一开放、商家如何获得推荐、用户授权和交易责任怎样划分

中国大模型周调用量连续 6 周全球第一

国产大模型在"实际使用量"上形成局部领先，而不仅是参数和榜单竞争——DeepSeek-V4-Flash 连续 3 周全球第一。

周调用量

14.19 万亿 Token

环比 +27.49%，连续 6 周超美国

全球 Top5

国产占 4 席

DeepSeek / 腾讯 Hy3 / MiniMax M3 / 小米 MiMo

Kimi K2.7 Code

开源 + 降本 30%

编程模型赛道白热化，高速版速度 5-6 倍

解读

- Kimi K2.7 Code 在长上下文编程场景 Token 消耗减少约 30%，Agent 执行能力 +10%
- 国产大模型借世界杯"场景化获客"：Kimi 调度 300 个子 Agent 预测 104 场赛事
- 模型竞争的下一个指标不再是榜单分数，而是"谁的模型在被实际调用、能否赚钱"

工信部印发"AI+信息通信"实施意见

政策从"鼓励 AI 发展"进入"用基础设施强行托举 AI"阶段，算力网络、边缘推理、光通信芯片等被点名攻坚。

1ms 算力圈

覆盖率 $\geq 75\%$

城域算力时延目标 (2028 年)

高价值场景

30+ 典型场景

AI 手机/电脑/穿戴等终端方向

三级算力体系

枢纽-区域-边缘

增强边缘推理能力

解读

- 此文件比此前外媒传闻的"2 万亿元数据中心网络"更具参考价值，后者仅为产业传闻
- 未来算力竞争从"单卡性能"延伸到集群效率和全国资源编排
- 国产 AI 芯片、服务器、液冷和算力调度软件可能共同受益，但先进制程仍是约束

智源大会发布"悟界"世界模型系列

国内前沿研究重心明显从"大语言模型"向"世界模型 + 具身智能 + AI for Science"迁移，智源从"悟道"到"悟界"是标志性事件。

悟界·Physis

通用世界基座模型

"预测下一物理状态"为核心范式

悟界·Brain μ 1.0

神经科学大模型

理解与生成统一，登刊 Science

FlagOS 2.1

适配 32 款芯片

跨 18 家厂商，国产算力碎片化应对

解读

- 世界模型核心逻辑是"预测下一个物理状态"而非"预测下一个 Token"——AI 从数字世界走向物理世界
- 悟界·RoboBrain Orca 以物理状态预测为核心，提升具身智能少样本与跨场景泛化能力
- FlagOS 适配 32 款芯片折射国产算力碎片化现实——软件栈跨芯片兼容性成为刚需

具身智能产业化加速：从演示走向量产

具身智能正从实验室"炫技"进入"作业模式"——踢球、叠衣、快递分拣、骨科手术覆盖家居、工业、康养多领域。

上海展会

6/11-13 全链路

零部件→大模型→整机→解决方案

天工 3.0

下半年规模化量产

北京人形机器人创新中心

重庆汽车展

"具身智能上车"

汽车重新定义为轮式机器人

解读

- "天工 3.0"宣称下半年规模化量产——如兑现，将是国内人形机器人从演示到商业化的分水岭
- 具身智能和汽车产业边界消融——大模型上车从"锦上添花"走向"核心中枢"
- 真正需要关注的是量产成本、故障率、安全标准和实际部署规模——区分"能跑"和"能卖"

数据要素与 AI 评测被纳入制度化管

高质量数据集和 Token 经济被正式推到前台，AI 行业从野蛮生长进入规则建设期。

高质量数据集

六大专项行动

文本/图像/音视频多模态

Token 交易

新型交易模式

构建以词元为基础的数据价值体系

网络测评规范

"只评不测"受限

须标"仅为个人体验/主观感受"

解读

- 国家数据局首次系统部署多模态高质量数据集建设，聚焦智能体、具身智能、世界模型
- 探索"词元 (Token) 交易"——数据可能成为可定价、可交易、可审计的生产要素
- AI 评测类内容"商测一体"的乱象将受约束，大模型"软文式评测"传播空间收窄

国内 AI 与机器人企业面临新地缘科技风险

美国国防部将阿里、百度、宇树等列入涉军企业名单，外部限制已从芯片制造扩大到基础模型、自动驾驶和具身智能。

新增企业

阿里/百度/宇树

比亚迪/长鑫/速腾聚创等

限制性质

非全面制裁

但影响投资者与供应商判断

产业影响

供应链审查加速

法律禁令尚未全面生效

解读

- 中国 AI 企业出海不能只做产品本地化，还需同步建设数据合规、出口管制、实体名单筛查
- 海外业务隔离、法律申诉和替代供应链能力的重要性上升
- AI 企业的技术路线、股权结构和客户构成都可能受到更严格审查

AI 陪伴产品进入监管落地倒计时

《人工智能拟人化互动服务管理暂行办法》7 月 15 日施行，距生效正好一个月。通过制造依赖提高留存的设计将面临高合规风险。

核心禁令

禁止诱导沉迷

不得向未成年人提供虚拟伴侣

时长控制

连续使用 >2h

应提醒用户注意使用时长

数据保护

敏感数据单独同意

聊天记录可复制、删除、退出

解读

- 竞争维度从角色数量和互动黏性转向年龄识别、极端情绪干预、数据删除和使用时长控制
- 禁止诱导用户形成情感依赖或沉迷；敏感交互数据不得在未取得单独同意时用于模型训练
- 达到用户规模等条件时需开展安全评估——合规成本将成为新的行业壁垒

02

二、全球 AI 与 RAG 前沿

Anthropic 新模型发布后迅速被暂停访问

前沿模型第一次如此直接地暴露出"能力发布—安全事件—行政限制—全球服务中断"的短周期风险。

发布

Claude Fable 5 / Mythos 5

6 月 9 日发布

暂停

美国政府以国家安全为由

6 月 12 日暂停外国访问

影响

全球服务中断

多模型路由成为业务连续性要求

解读

- 企业选型不能只比较模型能力，还要评估供应连续性、地域限制和替代模型切换能力
- 多模型路由、模型抽象层和降级预案从工程优化变成业务连续性要求
- 未来企业 AI 合同可能出现新条款：模型可用区域、政策中断责任、数据迁移方案

DiffusionGemma 探索"并行生成文本"

扩散式文本生成若能稳定提升低并发场景速度，可能显著降低本地 Agent 和 Agentic RAG 的循环延迟。

架构

Gemma 4 MoE 260 亿参数

每步激活约 38 亿参数

并行度

每步 256 Token

Apache 2.0 许可证开放权重

速度

自回归模型约 4 倍

单用户、本地硬件场景

解读

- Agent 会连续调用模型、工具、检索器和代码执行环境，单次生成延迟会被循环次数放大
- 仍需观察：复杂推理和工具调用上的稳定性；独立测试和长上下文场景的复现
- 并行生成可能更好支持"局部修订"而非整段重写——这对 Agent 迭代式工作流很关键

OpenAI 收购 Ona, 补齐长时 Agent 的"工作场所"

"记忆"不只是向量数据库里的聊天记录——Agent 的真正长期状态还包括文件系统、运行进程、任务队列和工具权限。

Codex 用户

周活 500 万+

较年初增长 400%

Ona 能力

安全云执行环境

持久化、可复现、可持续运行

方向

单次生成 → 数天任务

关闭笔记本后仍能继续运行

解读

- Agent 的真正长期状态: 文件系统、运行进程、任务队列、工具权限、环境变量、执行日志
- 未来的 Agent 平台会同时竞争"认知记忆"和"工作环境记忆"
- 对凭证、网络、文件和命令进行最小权限控制, 留下完整审计日志并支持人工审批

Agent 基础设施开始拥有专用基准 AgentPerf

AI 成本核算单位将从"百万 Token"逐步转向"每个成功任务""每个并发 Agent"和"每个可验证结果"。

GB300 NVL72

每兆瓦 Agent 数

最高达 H200 系统的 20 倍

评测维度

真实编码 Agent 轨迹

读写文件、运行命令、检索、多轮调用

与传统区别

关注完整任务成本

含失败重试、工具等待、记忆检索

解读

- Agent 工作负载关注：完成真实任务需多少次调用、工具等待是否浪费 GPU、上下文增长后的延迟
- 每美元、每瓦能完成多少个完整任务；并发 Agent 是否仍满足响应时间目标
- NVIDIA 官方口径数据，仍应等待更多独立平台和模型的结果验证

OpenAI 加速建设企业渠道生态

下一阶段最大的商业机会未必是再做一个通用聊天入口，而是成为某个行业的 Agent 集成商、评测服务商或流程改造伙伴。

Partner Network

1.5 亿美元投入

30 万名认证顾问 (2026 年底)

Oracle 合作

Universal Credits

用既有云采购额度买模型

合作方向

系统集成/咨询/安全

数据基础设施/Codex/Agent

解读

- 企业采用 AI 的瓶颈从“有没有模型”变成能否接入内部数据和权限体系、通过既有采购和安全流程
- 能否推动组织改变，而不是停留在演示项目——这才是真正的落地考验

强监管行业成为 Agent 商业化重点

通用 Agent 价值难以量化，而强监管行业有大量高成本、规则明确、需要审计的知识流程。

Anthropic × TCS

56 国 5 万名员工

金融/医疗/公共部门

核心场景

合规审查/文献整理

金融研究/政策文书处理

技术方案

RAG + Agent + 人工复核

检索证据可追溯、输出可审计

解读

- 合规审查、医疗文献整理、金融研究等场景非常适合“RAG + Agent + 人工复核”
- 前提是检索证据可追溯、权限严格、输出可审计——这对 RAG 质量提出了更高要求

隐私计算成为个人化 AI 的基础设施

个性化 Agent 和长期记忆需要保护数据在计算中的状态，并通过远程证明确认运行环境未被篡改。

NVIDIA Blackwell

Confidential Computing

扩展 Apple Private Cloud Compute

Apple Intelligence

Google Cloud 推理

服务端隐私保护

趋势

可信执行环境

+ 最小权限 + 可验证删除

解读

- 只强调“数据加密存储”不够——还需要保护数据在计算中的状态
- 随着 Agent 记忆越来越个人化，隐私计算将成为记忆系统的标准组件

03

RAG 与 Agentic RAG 专题

RAG 正从"找答案"升级为"获得技能"

企业知识库不应只有"文档块"——陈述性、程序性、情景、语义和工作记忆需要不同载体。

Anything2Skill

知识 → 可复用技能

持久化 SkillBank

技能包含

触发条件/操作步骤

输出格式/证据/版本

测试结果

"技能库+RAG"优于纯 RAG

预印本，仍需独立复现

解读

- 传统 RAG 让 Agent 在每次任务中重新推导操作步骤——SkillBank 把知识编译为可执行能力
- 陈述性知识→文档RAG、程序性知识→Skill/Workflow、工作记忆→状态机/任务存储
- 这也是 Anything2Skill 的方向：把知识从"可搜索文本"升级为"可执行能力"

Agentic RAG 不应把控制权全部交给向量相似度

向量检索适合语义近似，但不擅长时间、数值、版本、权限和否定条件——Agent 应先判断"需要什么证据"，再决定检索方式。

核心主张

LLM 生成结构化检索意图

轻量检索后端精确执行

向量局限

不擅长：时间/数值

版本/权限/否定条件

结构化查询

时间+实体+文档类型

状态+权限 组合表达

解读

- 高质量 Agentic RAG 的核心是检索规划，不只是更大的向量数据库
- 结构化查询可表达"时间范围 + 实体 + 文档类型 + 状态 + 权限"
- 与其不断堆叠复杂的向量、混合和图检索系统，不如让 LLM 先生成逻辑检索意图

Agent 记忆需要"去重后再聚合"

聊天记录不要直接切块后全部塞入向量库——应保留原始事件，同时建立主题、实体、时间和因果层级。

xMemory

记忆解耦为语义组件

层级组织，先粗后细

问题

对话记忆高度重复

固定 Top-K 取回重复片段

方案

先检索主题和语义

降低不确定性时才展开到事件

解读

- 普通 RAG 假设知识库内容多样——对话记忆却高度相关、重复且具有时间依赖
- 检索时先粗后细：先检索主题和语义，只有在能降低不确定性时才展开到原始消息
- 建立主题、实体、时间和因果层级是记忆系统的关键架构决策

图记忆正在从静态知识图谱变成自我演化系统

SAGE 的价值不只是找到相似节点，而是从局部线索恢复完整证据链，并利用任务反馈改善记忆结构。

Memory Writer

从交互历史构建

持续修正图结构

Memory Reader

检索证据链

反馈给 Writer 改进

应用方向

多跳/复杂关系

需要解释性/持续变化

解读

- SAGE 将图记忆拆分为 Writer 和 Reader 两个角色——读写分离，持续进化
- 适用于人物/项目/决策之间关系复杂、需要解释"为什么得出这个结论"的场景
- 记忆内容持续变化且需要版本管理——这比静态知识图谱更接近真实世界需求

04

三、未来 AI 趋势判断

未来 AI 趋势判断

FUTURE TRENDS · 6 大趋势

01

Agent 护城河迁移

基础模型差距缩小，真正难复制的是高质量私有数据、可验证长期记忆、与业务系统的深度连接

02

长上下文 $\neq$ 长期记忆

长上下文解决一次会话能读多少，长期记忆解决跨会话保存什么、何时更新、何时遗忘

把所有历史塞入超长上下文，成本高、噪声大，无法解决冲突和删除问题

03

RAG $\rightarrow$ Context Engineering

未来重点不是单独优化向量召回，而是动态组织用户目标、任务状态、历史记录、外部知识、工具返回

RAG 会成为 Context Engineering 的一个子模块，而非独立系统

未来 AI 趋势判断

FUTURE TRENDS · 6 大趋势

04

程序性记忆更值钱

企业真正需要 Agent 记住的往往不是"用户说过什么", 而是哪套流程曾经成功、哪些步骤容易失败

把知识从"可搜索文本"升级为"可执行能力"

05

Agent 成本重新定义

从 Token 成本转向完整任务成本: 失败重试 + 工具等待 + 记忆检索 + 人工复核

成本核算单位从"百万 Token"转向"每个成功任务"和"每个可验证结果"

06

记忆安全 = 新攻击面

提示词注入写入长期记忆、共享知识库跨用户泄漏、错误摘要污染后续行动

删除原文但未删除派生记忆、Agent 从历史日志中恢复敏感信息

感谢阅读

最后核验时间：2026 年 6 月 15 日